CampusClaw

# AI 平台五项功能与 LLM 请求核验报告

代码行为核验 · 接口与数据库测试 · GitHub 交付

核验日期：2026 年 10 月 27 日 | 范围：当前 Go + React + MySQL + Qdrant 工作树

## 项目简介

CampusClaw 是面向班级教学的可追溯 AI 平台。教师可维护多个教学智能体、提示词模板、技能和材料绑定；学生使用 JWT 登录后在本班智能体中建立会话。系统以 MySQL 保存材料、切片和会话，以 Qdrant 做向量检索，并通过 OpenAI 兼容网关提供流式回答。MCP 宿主可以发现并调用授权的外部教学工具。

Git 仓库：github.com/ariayue0525/campusclaw-traceable-retrieval

## 结论速览

| 核验问题 | 结论 |
| --- | --- |
| 每轮 LLM 请求与模板 | 流式会话发送 model、messages、temperature=0.2、max_tokens=600、stream=true；绑定模板只在智能体 prompt 为空且模板启用时渲染进入 system。旧 /api/ask 不使用智能体模板。 |
| 知识库内容 | 不会发送全库。每轮只取当前班、所选智能体绑定材料及命中技能资料范围内最多 4 条有效切片。 |
| Skill 内容 | 不会发送整个技能文件。只将本轮命中技能的说明正文放入 system；元数据用于路由、筛选和工具声明。 |
| Skill 执行 | 先按关键词确定性选一个技能，再让模型遵循其引导规程；可选工具由模型发起函数调用，经宿主校验后执行。 |
| MCP 请求参数 | 只把当前技能允许且已连接工具的函数名、描述和 JSON 参数模式发给 LLM；MCP 地址和令牌不发送。 |

重要边界：本机未配置 LLM_GATEWAY_API_KEY 和 MCP_AUTH_TOKEN。以下“通过”指代码、模拟 OpenAI 网关加真实 MySQL 的流式测试，以及临时令牌下的真实 MCP 服务协议测试；不能据此宣称已用正式模型密钥完成线上调用。

## 1. 每次对话给 LLM 的参数、返回内容与模板

新接口 POST /api/conversations/{id}/messages/stream：服务端先确认会话归属、读取当前智能体、路由技能并做限定检索。调用 OpenAI 兼容网关的 POST /chat/completions；HTTP 头含 Content-Type: application/json、Accept: text/event-stream，以及仅在配置密钥时才附加的 Authorization: Bearer。请求体结构如下（尖括号仅为字段说明，不是真实对话内容）：

```
{
  "model": "gpt-4o-mini", "temperature": 0.2,
  "max_tokens": 600, "stream": true,
  "messages": [
    {"role":"system","content":"<角色提示词或渲染模板>\n<命中技能正文>\n<固定安全规则>"},
    {"role":"user","content":"[1] <材料标题/段号/位置/摘录>\n学生本轮问题：..."}
  ],
  "tools": ["<仅本轮允许的函数声明，可省略>"],
  "tool_choice": "auto（仅 tools 非空时）"
}
```

系统消息只包含角色设定、命中技能正文和固定约束；材料摘录放在 user 消息中。历史上下文最多读取最近 6 条消息，每条给模型最多 500 字。当前学生问题最长 4000 字。若智能体自有 prompt 非空，它优先于绑定模板；否则渲染已启用模板中的 {{student_name}} 和 {{class_name}}；再否则使用服务端默认角色。

网关流式返回逐段的 choices[0].delta.content、可能分片到达的 delta.tool_calls，以及终止标记 [DONE]。宿主把正文增量转成前端 SSE：先 meta（技能与引用），再多次 delta；助手消息落库成功才发 done（消息 ID）；故障发 error。测试确认 2 个 delta 拼接与 MySQL 持久化回答完全一致。

兼容旧接口 POST /api/ask 使用非流式 Complete：请求包含 model、两条 system/user 消息、temperature=0.2 和 max_tokens=600；不含智能体模板、Skill 或工具声明。正常 JSON 响应从 choices[0].message.content 提取。无检索命中时旧接口不调用 LLM；新流式接口无命中仍可调用模型，但引用为空。

## 2. 绑定知识库后，会发送全部内容吗？

不会。新流式接口在检索前计算材料允许集：当前用户实时班级 ∩ 当前智能体绑定材料 ∩ 命中技能的“资料”标题范围。关键字 SQL 与 Qdrant 查询均带材料 ID 范围，Qdrant 还按 class_id 预过滤；最终 MySQL 回表再校验班级、材料和 ready 状态。混合检索按 RRF 排序后最多选 4 条。

模型实际收到的是这些命中切片的标题、段号、来源位置和摘录，不是整份文件，更不是全库。每条送入模型的上限为 800 字；当前默认 SNIPPET_MAX_CHARS=240，所以默认通常是最多约 240 字的摘录。Qdrant 保存向量和关联 ID，不保存材料正文。未绑定材料不会进入引用；无命中时 citations 为空。

## 3. 绑定 Skill 后，会发送技能全部内容吗？

不会自动发送，也不会发送完整原始文件。每轮先读取当前智能体绑定且启用的技能。仅当本轮问题命中“适用条件”关键词时，才选出一个技能；其 description（技能文件空行之后的说明正文，最多 2000 字）完整进入 system 消息。source_text 中的名称、适用条件、资料、工具、启用字段不作为原样文本送入模型。

这些元数据仍发挥作用：名称用于前端 meta 与消息记录；适用条件用于路由；资料用于检索前过滤；工具字段控制本轮可向 LLM 暴露的函数声明。技能文件整体上限 8000 字，因此“完整文件”与“送入模型的正文”是两个不同概念。未命中、未绑定或已停用的技能不会进入 system。

## 4. 具体 Skill 如何执行？

| 顺序 | 服务端实际逻辑 |
| --- | --- |
| 1 路由 | 对本轮问题与每个已绑定且启用技能的适用条件做大小写不敏感子串匹配；每命中一个关键词加 1 分。最高分胜出，同分取最小 ID；零分不选。 |
| 2 限定知识 | 用选中技能的资料字段约束智能体已绑定的材料集，再按班级及 ready 切片检索；最多 4 条。 |
| 3 组装提示词 | 将技能说明正文放入 system，检索摘录放入 user；技能本身不是任意脚本，不会被直接执行。 |
| 4 工具调用 | 若技能声明 knowledge_search 或 MCP 工具，只向模型提供允许的函数声明。模型可发起 tool_calls；宿主核对函数名、参数模式与当前连接状态，执行后把结果作为 role=tool 数据消息送回模型。 |
| 5 限制与记录 | 最多 3 轮模型请求、4 次工具调用；MCP 成功 / 拒绝 / 错误写入审计。回答保存后 SSE 发 done。 |

内置“数学解题引导”规程要求只引导学生思考，不直接给最终答案、选项、得数或完整解题过程。它是提示词约束，不是形式化的答案防泄漏证明；实际模型表现仍需在配置正式网关后做内容评测。

## 5. MCP 接入后，每轮给 LLM 什么？

登记与发现 MCP 服务是独立流程：宿主向服务发送 initialize、tools/list；实际调用发送 tools/call。上述请求携带 MCP Bearer 令牌，但这些网络参数不进入 LLM 请求。

```
{
  "tools": [{"type":"function","function":{
    "name":"mcp_tool_<数据库工具ID>",
    "description":"<发现时保存的工具描述>",
    "parameters":{"type":"object","properties":{"topic":{"type":"string"}},
                  "required":["topic"]}
  }}],
  "tool_choice":"auto"
}
```

只有本轮选中的 Skill 显式声明、属于当前班级且当前已连接的 MCP 工具才会出现在 tools 中；未选中 Skill 时 tools 和 tool_choice 都省略。模型若返回 tool_calls，宿主校验参数、调用 MCP、截断并标注不可信工具输出，以 role=tool 和 tool_call_id 追加到下一次 /chat/completions 请求。模型能看到工具结果数据，但看不到 MCP URL、Bearer 令牌或其他未授权工具。

## 测试证据与上线边界

| 核验手段 | 本次结果 |
| --- | --- |
| Go 全量单元测试 | docker run --rm campusclaw-platform-test go test ./... -count=1；所有已测试包通过。 |
| 流式集成测试 | 真实 MySQL + 模拟 OpenAI 兼容网关：模板渲染进入 system；meta 先于增量正文；2 个 delta 与落库回答一致；无证据 citations 为空。通过。 |
| MCP 端到端测试 | 临时内网 MCP 服务 + 模拟 OpenAI 网关：只暴露选中技能的工具、真实 tools/call、结果回传模型、审计持久化、断开后立即不可选。通过；测试服务已停止。 |
| 接口自动化 | apitest/run_all.py：10 项通过、0 跳过、0 失败；涵盖登录、三模式检索、智能体、模板、技能文件上传、会话、SSE、MCP 和 Swagger，并核对数据库持久化。 |

不能声称完成的在线验证：本机 .env 的 LLM_GATEWAY_API_KEY 与 MCP_AUTH_TOKEN 均未配置。当前部署无法向正式 LLM 网关发起新流式会话，也没有常驻启用的 MCP 服务。上述流式与工具调用验证采用可复现的模拟网关；MCP 协议端是真实服务。要验证正式模型返回内容，需用户在未提交的 .env 中配置合法密钥后再运行在线验收。

## 主要源码与可复核位置

请求序列化与流解析：backend/internal/llm/chat.go；流式提示词与 SSE：backend/internal/server/stream.go；工具筛选与执行：backend/internal/server/toolflow.go；技能路由：backend/internal/retrieval/skillroute.go；限定检索：backend/internal/retrieval/service.go、backend/internal/vector/qdrant.go；技能文件解析：backend/internal/skillfile/parse.go；MCP 协议：backend/internal/mcpbridge/client.go、backend/internal/mcpserver/server.go；集成断言：backend/internal/server/stream_integration_test.go。

GitHub 仓库：https://github.com/ariayue0525/campusclaw-traceable-retrieval